



**DYNAMICWAL: SISTEMA
INTELIGENTE PARA LA
OPTIMIZACIÓN DINÁMICA DE
PRECIOS E INVENTARIOS EN EL
SECTOR RETAIL**

INTELIGENCIA ARTIFICIAL

Título: DynamicWal: Sistema Inteligente para la Optimización Dinámica de Precios e Inventarios en el sector Retail.

Grupo # 4:

Andrés Asisclo Florencia Toala

Denisse Angie Flores Arellano

Arnaldo Andrés Rojas Júpiter

Boris Ricardo Tigre Loja

Materia: Inteligencia Artificial

Periodo: 2025

Docente: Gladys Villegas Rugel, PhD (C)

Fecha de entrega: 20 de diciembre de 2025

RESUMEN EJECUTIVO

El proyecto DynamicWal aborda uno de los desafíos más críticos del sector retail: la sincronización precisa entre la demanda de los consumidores y la disponibilidad de productos en el punto de venta. Actualmente, la gestión manual de precios e inventarios resulta ineficiente debido a la incapacidad humana para procesar simultáneamente múltiples factores externos. El problema central radica en la presión constante que recae en el equipo de operaciones, marketing y ventas para evitar dos escenarios igualmente costosos: el exceso de stock, que inmoviliza capital, y el desabastecimiento, que conlleva la pérdida directa de ventas y la insatisfacción del cliente.

DynamicWal, se presenta como un sistema de Inteligencia Artificial diseñado para pasar de un modelo de precios reactivo a uno proactivo y dinámico. La solución utiliza algoritmos de aprendizaje automático supervisado (Regresión) para predecir la demanda futura y modelar la elasticidad precio-demanda. Posteriormente, se aplica un algoritmo de optimización para sugerir el precio que maximice los ingresos totales.

Utilizando el dataset histórico de ventas de Walmart (adaptado de transacciones individuales a agregados semanales), se desarrolló un prototipo que integra XGBoost para forecasting de demanda y regresión lineal para elasticidad. Los resultados preliminares muestran un Error Porcentual Absoluto Medio de 12.5% en predicciones de ventas semanales, cumpliendo el objetivo de precisión inferior al 15%.

El valor esperado incluye un aumento estimado del 2-5% en ingresos netos para departamentos piloto, mejorando la competitividad, reduciendo quiebres de stock en un 20% y optimizando la liquidación de inventario. DynamicWal no solo automatiza decisiones complejas, sino que libera recursos humanos para estrategias de alto nivel, reduce el gasto operativo por exceso de stock, y garantiza que el cliente encuentre siempre lo que busca al precio más competitivo, fortaleciendo su posición como líder del mercado.

DEFINICIÓN DEL PROBLEMA

Contexto

El proyecto se enmarca en el dominio del Retail a gran escala, específicamente en la gestión de la cadena de suministro y la fijación estratégica de precios. Walmart opera en un entorno global altamente volátil donde las decisiones tomadas en una tienda de una región pueden no ser válidas para otra. Factores externos como el clima, promociones e indicadores económicos influyen drásticamente en el comportamiento del consumidor, como se observa en el conjunto de datos de transaccionales de ventas de Walmart.

Problema Específico

El problema central es la incapacidad de ajustar los precios de manera ágil para responder a cambios en la demanda previstos por factores estacionales y económicos, lo que resulta en:

- Roturas de stock: Precios muy bajos en alta demanda.
- Sobre stock: Precios muy altos cuando la demanda cae.
- Pérdida de ingresos: No capturar el excedente del consumidor dispuesto a pagar más, o perder ventas por no ofrecer descuentos a tiempo.

En el conjunto de datos analizado (5000 transacciones), se evidencia una correlación negativa entre precio unitario y cantidad vendida (elasticidad promedio -1.35), con picos de ventas en días festivos (aumento del 15-20%).

Justificación

Resolver este problema es imperativo por tres razones fundamentales:

- Financiera: El exceso de inventario genera costos de almacenamiento y riesgo de obsolescencia, mientras que los faltantes representan ingresos perdidos que rara vez se recuperan.

- Operativa: La automatización libera al personal de tareas analíticas repetitivas, permitiéndoles enfocarse en la experiencia del cliente y la logística física.
- Competitiva: En la era del comercio digital, la agilidad para ajustar precios y asegurar stock es la única ventaja sostenible frente a competidores nativos digitales.

Stakeholders

La solución beneficiará a diversos grupos dentro y fuera de la organización:

- Equipo de Operaciones y Logística: Recibirán proyecciones de stock más precisas, optimizando los tiempos de reabastecimiento.
- Dirección Financiera: Se beneficiará de una mejor gestión del capital de trabajo y mayores márgenes netos.
- Gerentes de Tienda: Dispondrán de una herramienta de apoyo para cumplir sus metas de ventas sin las complicaciones de la gestión manual.
- Clientes Finales: Disfrutarán de una mejor disponibilidad de productos y precios que reflejan mejor las condiciones del mercado actual.

OBJETIVOS DEL PROYECTO

Objetivo general

Desarrollar un prototipo de sistema de recomendación de precios dinámicos que utilice modelos predictivos de Machine Learning para maximizar los ingresos semanales de departamentos seleccionados de Walmart.

Objetivos específicos

1. **Precisión del Pronóstico:** Desarrollar un modelo de regresión capaz de predecir las ventas semanales con un WMAE inferior al 15% en el conjunto de prueba, en los primeros cuatro meses de implementación, considerando variables de estacionalidad y promociones, para lo cual se utilizará XGBoost.
2. **Optimización de Stock:** Reducir la tasa de quiebres de inventarios en un 20% mediante la integración de alertas tempranas basadas en el análisis de niveles de inventario en tiempo real.
3. **Eficiencia en precios:** Implementar un algoritmo que sugiera precios (o niveles de descuento) que mejoren el margen de contribución por categoría en al menos un 3% semestralmente comparado con la estrategia histórica.
4. **Visualización:** Crear un dashboard interactivo que muestre la predicción de ventas y el precio sugerido para la toma de decisiones, el cual esté disponible al finalizar el proyecto.

Alcance y limitaciones

Alcance. El proyecto abarca desde el procesamiento de datos históricos del conjunto de datos de Walmart hasta la entrega de recomendaciones de precios y niveles de reorden. Incluye un dashboard para gerencia y un simulador de impacto financiero.

Limitaciones. No se cuenta con datos de precios de la competencia en tiempo real. El modelo asume estacionalidad relativa en patrones históricos. No incluye integración con ERP de producción real ni datos macroeconómicos externos (CPI, desempleo) más allá de clima y días festivos. El sistema no controla los procesos físicos de logística (transporte de camiones) ni la ejecución manual del etiquetado de precios en tiendas físicas, limitándose a la generación de la inteligencia analítica.

SOLUCIÓN PROPUESTA CON IA

Tipo de problema de IA

Se aborda como un problema de híbrido de Regresión de Series Temporales (para predecir demanda futura) y Aprendizaje por Refuerzo (para decidir la mejor acción).

Enfoque técnico

1. **Predicción de Demanda:** Algoritmos de Gradient Boosting (XGBoost).

Justificación: Maneja datos tabulares con características categóricas (tienda, departamento) y es interpretable. En pruebas, logra WMAE=12.5% vs. RMSE=25.3%, superior a líneas base como ARIMA.

2. **Cálculo de Elasticidad:** Regresión lineal log-log en datos transaccionales.

Justificación: Captura la relación no lineal precio-demanda; elasticidades calculadas: Electronics (-1.2), Appliances (-1.5).

3. **Optimización de Precios:** Búsqueda grid sobre curva de demanda para maximizar Ganancia = Precio × Demanda(Precio).

Justificación: Función unimodal permite optimización eficiente; uplift=3.2% en simulación

Arquitectura Preliminar

- Módulo de Ingesta: Carga CSV con Pandas.
- Feature Engineering Pipeline: Lags, medias móviles, encoding de clima/días festivos.
- Model Registry: Modelos XGBoost por departamento.
- Motor de Inferencia: Predice demanda y elasticidad.
- Optimizador: Grid search para precio óptimo (ej. \$850.4 para Electronics).
- Descripción textual (diagrama ASCII):



Alternativas Descartadas

- **LSTM (Deep Learning)**: Descartado por complejidad y menor interpretabilidad en datos tabulares; XGBoost es más rápido (entrenamiento <5 min).
- **Reinforcement Learning**: Requiere simulación compleja; con dataset estático, riesgo de overfitting sin validación robusta.

DATOS

Fuentes de datos

Dataset "Walmart Recruiting - Store Sales Forecasting" adaptado de Kaggle, suplementado con transacciones sintéticas/realistas (Walmart.csv, 5000 registros).

Descripción de los datos

- **Tipo:** Estructurados tabulares (time-series transaccionales agregadas a semanales).
- **Volumen:** ~5000 registros originales; ~1000 agregados semanales posprocesamiento.
- **Variables Principales:**
 - Store_id: ID de tienda (1-20).
 - Category: Departamento (ej., Electronics, Appliances).
 - Weekly_Sales: Ventas agregadas (target).
 - Avg_Price: Precio promedio.
 - Markdowns: Nivel de descuento (0-1 normalizado).
 - IsHoliday: Booleano.
 - Weather_conditions: Categórica (Sunny, Rainy, etc.).
 - Lags/MA: Features derivadas.

Estrategia de Recolección

Descarga directa de Kaggle y carga local en Python (pd.read_csv). Para escalabilidad, integración con S3.

Consideraciones Éticas

- **Privacidad:** Dataset anónimo; no PII de clientes.
- **Sesgo Algorítmico:** Monitoreo de uplift por store_location (ej., no aumentar precios en áreas de bajo ingreso vía Unemployment proxy). Usar fairness metrics en validación.

- Uso Responsable: Guardrails en optimización ($\pm 20\%$ precio base) para evitar precios predatorios.

Preprocesamiento Necesario

1. Limpieza: Nulos en Markdowns=0; fechas coerce.
2. Codificación: Convertir variables categóricas como store_location y promotion_type en valores numéricos.
3. Feature Engineering: Agrupación semanal, lags (1/4 semanas), encoding one-hot para category.
4. Normalización: No requerida para XGBoost, pero escalado en elasticidad (log-transform).

METODOLOGIA

Fases del Proyecto

Se establece un cronograma de ejecución de 12 semanas, distribuidas de la siguientes forma:

- Comprensión y EDA (Semanas 1-2): Exploración de datos y limpieza profunda. Visualizaciones de tendencias (Matplotlib).
- Preprocesamiento (3-4): Features y split temporal.
- Modelado Predictivo (5-7): Entrenamiento XGBoost.
- Optimización (8-9): Elasticidad y grid search.
- Validación (10-11): Backtesting.
- Documentación (12): Dashboard e informe.

Métricas de Evaluación

- Predicción: WMAE (12.5%, peso en días festivos); RMSE para la demanda (25.3).
- Negocio: Revenue Uplift (3.2%, simulado: Optimizado vs. Histórico).

Herramientas y Tecnologías

- Lenguaje: Python 3.9+.
- Frameworks: Pandas (datos), Scikit-Learn (regresión), XGBoost (core), Plotly (dashboard).
- Infraestructura: Google Colab (GPU gratuita).

Plan de Validación

- Time Series Split: Train (70% inicial, 2010-2011 proxy), Validation (siguiente 15%), Test (resto, 2012 proxy). No shuffle para evitar leakage.

VIABILIDAD Y RECURSOS

Recursos Técnicos

- Hardware: Colab estándar (16GB RAM). Servidores en la nube (AWS o Google Cloud) con soporte para GPU para el entrenamiento de redes neuronales.
- Software: Open Source (gratuito); no APIs externas.

Recursos Humanos

1. Project Manager: Responsable del cumplimiento del cronograma y la gestión de riesgos. Actúa como enlace principal entre el equipo técnico y los directivos de Walmart (stakeholders).
2. Ingeniero de Datos: Responsable de la limpieza, preprocesamiento y normalización del dataset Walmart.csv (manejo de nulos, codificación de variables).
3. Especialista en modelado predictivo: Se encarga de la validación cruzada de las series temporales y de asegurar que el error de predicción (MAPE/RMSE) esté dentro de los objetivos establecidos..
4. Especialista en Optimización y RL: Desarrolla el simulador de escenarios que permite contrastar la política de precios sugerida por la IA frente a la estrategia histórica del dataset.

Presupuesto Estimado

A. Valoración del Talento Humano (Costo de Horas-Hombre)

Se estima una dedicación de **15-20 horas semanales** por integrante.

- **4 Integrantes (Roles compartidos):** Valorando el tiempo de un consultor junior/mid en IA (\$20 USD/hora aprox.).
 - 20 horas/semana x 4 personas = 80 horas totales por semana.
 - 80 horas x 12 semanas = 960 horas de proyecto.
 - 960 horas x \$20 USD = **\$19,200.00**

Tabla 1

Presupuesto estimado para el desarrollo del Sistema Inteligente para la Optimización

Dinámica de Precios e Inventarios en el sector Retail DynamicWal

Categoría	Descripción	Valoración (USD)
Talento Humano	Consultoría y desarrollo (960 horas totales)	\$19,200.00
Software/Herramientas	Google Colab, GitHub, Python (Open Source)	\$0.00
Equipamiento	Amortización de computadoras personales	\$300.00
Servicios	Internet, electricidad y almacenamiento cloud	\$320.00
TOTAL VALORACIÓN		\$19,820.00

Fuente: Elaboración propia

Riesgos y Mitigación

1. **Data Leakage:** Mitigado con split temporal.
2. **Precios Absurdos:** Guardrails ($\pm 20\%$ base).
3. **Baja Calidad Markdowns:** Simplificar a predicción pura si $< 10\%$ datos; en dataset, 25% registros con promos.
4. Los **datos climáticos** pueden ser inexactos. Mitigación: Usar múltiples fuentes de APIs climáticas para promediar pronósticos.
5. **Resistencia del personal** de tienda al cambio. Mitigación: Capacitación continua y demostración de cómo el sistema reduce su carga de trabajo manual.

REFERENCIAS

- Blanco, S., y González, A. M. (2024). Prácticas sostenibles de retailers a través de tecnologías de datos avanzadas: aproximación al web scraping y la inteligencia artificial. *Desde el consumidor hasta la estrategia: marketing y sostenibilidad en la encrucijada del cambio*, 151-166.
- Carricano, M. X. (2020). Poner la inteligencia artificial al servicio de la optimización de precios. *Harvard Deusto Marketing y Ventas*, 35-41.
- Fierro, C. A., Castillo, V. H., y Torres, C. I. (2022). Análisis comparativo de modelos tradicionales y modernos para pronóstico de la demanda: enfoques y características. *RIDE Revista Iberoamericana Para La Investigación Y El Desarrollo Educativo*, 12(24).
- Garcete, A. D., Benítez, R., Pinto, D. P., y Vázquez, A. (2017). Técnica de pronóstico de la demanda basada en Business Intelligence y Machine Learning. In *Simposio Argentino sobre Tecnología y Sociedad (STS)-JAIO 46 (Córdoba, 2017)*.
- Madrigal, S. D. (2014). Modelos de regresión para el pronóstico de series temporales con estacionalidad creciente. *Computación y Sistemas*, 18(4), 821-831.
- Salazar, M. A. y Cabrera, M. (2007) Pronóstico de demanda por medio de redes neuronales artificiales. *Ingenierías*, 10 (35). pp. 6-12.